PROYECTO INTEGRADOR | BASES DE DATOS AVANZADAS

Data Warehouse del Ecosistema Futbolístico Transfermarkt

PostgreSQL 16 | Arquitectura Medallón (Bronce, Plata, Oro)
Modelo de Constelación de Hechos (Kimball Bus Architecture)
Pipeline ETL en Python | Analítica Multidimensional en Power BI

DOCUMENTO DE SUSTENTACIÓN TÉCNICA Y GUÍA DE DEFENSA ORAL

Este documento técnico consolida los fundamentos arquitectónicos, el modelo dimensional de Constelación de Hechos, la metodología de calidad EDA, el pipeline de ingeniería de datos, las optimizaciones físicas en PostgreSQL y la estrategia analítica del proyecto integrador, diseñado para procesar y analizar más de **10,5 millones de registros** con tiempos de respuesta sub-segundo.

Programa: Ingeniería de Sistemas	**Asignatura:** Bases de Datos Avanzadas
Semestre: 5to Semestre Académico	**Institución:** Universidad Popular del Cesar
Integrantes: Juan Sebastián Rincón Farelo y equipo	**Docente:** Docente Titular de la Cátedra
Fecha: Octubre de 2026	**Ubicación:** Valledupar, Cesar, Colombia

ÍNDICE GENERAL DE CONTENIDO

Estructura capitular del documento de sustentación

Capítulo	Título del Capítulo y Alcance Temático	Pág.
1	**Resumen ejecutivo y contexto:** Problema, solución OLAP, alcance y cronograma.	3
2	**Objetivos y requerimientos:** Objetivo general, específicos, matriz RF01–RF10 y RNF01–RNF09.	4
3	**Volumetría y dimensionamiento físico:** Métricas reales (10,56 M), consumo en disco y SLAs.	6
4	**La base de datos de origen:** Las 7 entidades de Transfermarkt y contraste OLTP vs OLAP.	7
5	**Diseño del modelo de constelación de hechos:** Justificación Kimball, matriz de bus, DDLs.	9
6	**Arquitectura Medallón:** Roles por capa (Bronce, Plata, Oro, Meta) y stack tecnológico.	12
7	**Reglas del proceso EDA:** Catálogo E01–E10, calidad de datos y auditoría en meta.etl_rejected.	14
8	**Proceso ETL:** Flujo masivo por chunks con COPY, SQL set-based y expansión sintética.	15
9	**Capa Oro: agregaciones, índices y particiones:** Vistas materializadas concurrentes y partición.	17
10	**Dashboard Power BI y storytelling:** 4 páginas de negocio, medidas DAX y narrativa.	18
11	**Guía por diapositiva:** Resumen técnico y discurso de defensa para las 13 diapositivas.	20
12	**Banco de preguntas para la sustentación:** 15 respuestas directas y de alta rigurosidad.	23
13	**Puntos de atención y lista de verificación:** Checklist previo a la evaluación final.	25

Nota sobre la evolución arquitectónica: Este documento refleja la evolución definitiva desde el modelo estrella original hacia un **Modelo de Constelación de Hechos (Kimball Bus Architecture)**, con entidades en español en la capa Gold (*dim_**, *hecho_**, *agg_**) y validación empírica de 10.565.092 registros con 55 pruebas automatizadas pasando al 100%.

CAPÍTULO 1

Resumen ejecutivo y contexto

Qué problema se resuelve, qué se construye y cronograma de entrega

El fútbol profesional moderno toma decisiones críticas de reclutamiento (scouting), valorización de activos y planteamiento táctico fundamentándose en analítica de datos a gran escala. La plataforma Transfermarkt representa una de las fuentes abiertas más ricas a nivel global, abarcando competencias, clubes, perfiles de futbolistas, partidos, valoraciones de mercado y eventos detallados minuto a minuto. No obstante, explotar analíticamente estos datos sobre un esquema transaccional (OLTP) normalizado ocasiona consultas lentas, cuellos de botella por múltiples JOINs costosos y bloqueos con las escrituras operacionales.

Solución implementada: Se construyó un Data Warehouse (OLAP) de alto rendimiento en **PostgreSQL 16** utilizando la **Arquitectura Medallón** dividida en esquemas especializados: **Bronze** (ingesta cruda en texto con metadatos de linaje), **Silver** (limpieza, normalización relacional, tipado fuerte y reglas de calidad EDA E01–E10) y **Gold** (modelo multidimensional de Constelación de Hechos bajo la metodología Kimball y vistas materializadas). La orquestación se realiza mediante un pipeline modular en Python (procesamiento por bloques con COPY masivo) y el consumo analítico se canaliza hacia **Power BI** mediante tableros ejecutivos orientados a la toma de decisiones.

1.1 Alcance del proyecto en una frase

Alcance Global: Consolidar y procesar **10.565.092 registros** del ecosistema Transfermarkt en un Data Warehouse en PostgreSQL con **Modelo de Constelación de Hechos**, completamente auditado, idempotente y con tiempos de respuesta analítica sub-segundo (< 0,39 s), dando respuesta integral a 11 requerimientos funcionales de negocio a través de Power BI.

1.2 Cronograma y entregables del curso

Fecha	Hito de Entrega	Contenido Técnico Exigido	Capítulo
28 sep	Presentación inicial (5 min)	Introducción al dominio, objetivo general, específicos, requerimientos y volumetría preliminar.	Cap. 1, 2, 3
30 sep	Sustentación de modelo	Diseño del modelo dimensional, justificación de granos y separación en constelación de hechos.	Cap. 5
07 oct	Calidad y Arquitectura	Arquitectura Medallón, reglas EDA E01–E10, tipado, normalización y linaje técnico.	Cap. 6, 7
12 oct	Pipeline ETL y expansión	Implementación ETL en Python, carga por chunks, expansión controlada a 10,5M y validaciones.	Cap. 8, 9
14 oct	Sustentación final y BI	Dashboard en Power BI, storytelling, benchmarks de consulta OLAP y defensa del proyecto.	Cap. 10, 11, 12

CAPÍTULO 2

Objetivos y requerimientos del sistema

Qué se debe lograr y cómo se demuestra técnicamente su cumplimiento

2.1 Objetivo General

Diseñar, implementar y validar un Data Warehouse en PostgreSQL bajo Arquitectura Medallón y un Modelo de Constelación de Hechos (Kimball Bus Architecture) con dimensiones conformadas compartidas, procesando más de 10,5 millones de registros de Transfermarkt para soportar análisis multidimensional en Power BI con tiempos de respuesta inferiores a 3 segundos (SLA cumplido en < 0,39 s).

2.2 Objetivos Específicos

1. Ingesta masiva y linaje (Bronce): Aterrizar los 7 datasets CSV mediante COPY por bloques de 100.000 filas, preservando texto crudo y metadatos de auditoría (_load_id, _loaded_at, _source_file, _row_id).

2. Depuración e integridad (Plata): Aplicar reglas EDA E01–E10 para tipar datos, imputar nulos canónicamente y verificar 0 huérfanos con claves primarias y foráneas estrictas.

3. Modelado dimensional (Oro): Estructurar una Constelación con 7 dimensiones conformadas y 3 tablas de hechos independientes según su grano analítico.

4. Expansión controlada de volumen: Escalar el volumen desde 3,62 M reales hasta 10.565.092 registros sintéticos deterministas, trazables y 100% reversibles sin contaminar la analítica.

5. Optimización física: Particionar por rango anual la tabla masiva de eventos (1990–2035) y crear índices B-Tree y Hash para maximizar partition pruning.

6. Explotación analítica: Precalcular vistas materializadas concurrentes y diseñar un dashboard de 4 páginas en Power BI conectado vía PostgreSQL.

2.3 Matriz de Requerimientos Funcionales (RF01 – RF10)

ID	Requerimiento Funcional de Negocio	Entidad Gold / Resolución Técnica
RF01	Top goleadores y asistidores por temporada y liga.	gold.hecho_rendimiento_jugador + gold.agg_jugador_temporada_liga
RF02	Rendimiento comparativo por posición y rol en el campo.	gold.hecho_rendimiento_jugador + gold.dim_jugador(posicion, sub_posicion)
RF03	Evolución temporal del rendimiento de jugadores a lo largo de los años.	gold.hecho_rendimiento_jugador + gold.dim_fecha(temporada)
RF04	Tabla de posiciones y puntos por club y temporada (3, 1, 0 pts).	gold.dim_partido(goles_local, goles_visitante) + gold.agg_club_temporada
RF05	Relación y correlación estadística entre valor de plantilla y puntos.	gold.hecho_valoraciones_mercado + gold.agg_club_temporada (corr() en PG)
RF06	Disciplina arbitral: promedio de tarjetas por partido y por 90 min.	gold.hecho_eventos_partido + gold.agg_disciplina_arbitro
RF07	Distribución temporal de goles y tarjetas por franjas de 15 minutos.	gold.hecho_eventos_partido(franja_15min) + gold.agg_eventos_15min
RF08	Módulo de scouting de promesas Sub-23 (rendimiento vs tasación).	gold.hecho_rendimiento_jugador + gold.dim_jugador(fecha_nacimiento)
RF09	Balance local vs visitante: porcentaje de victorias y goles.	gold.dim_partido + gold.agg_local_visitante
RF10	Precalculo y aceleración OLAP mediante vistas materializadas.	5 vistas gold.agg_* con UNIQUE INDEX y REFRESH CONCURRENTLY

2.4 Matriz de Requerimientos No Funcionales (RNF01 – RNF09)

ID	Requerimiento No Funcional	Mecanismo de Implementación y Evidencia Técnica
RNF01	Carga por bloques (Chunk Size)	Ingesta masiva en Python con pandas y comando COPY de PostgreSQL por chunks de 100.000 filas.
RNF02	Integridad referencial estricta	Restricciones FK en Silver y Gold. Cero registros huérfanos verificado por consultas de validación.
RNF03	SLA de consulta analítica < 3 s	Benchmarks en PostgreSQL: todas las consultas clave responden entre 0,001 s y 0,386 s (meta < 3,0 s).
RNF04	Vistas materializadas actualizables	Índices únicos en todas las vistas gold.agg_* permitiendo REFRESH MATERIALIZED VIEW CONCURRENTLY.
RNF05	Estandarización de fechas	Conversión uniforme a DATE ISO-8601 mediante función en PL/pgSQL meta.to_date.
RNF06	Imputación controlada de nulos	Reglas E01 (métricas a 0), E02 (valor de mercado a NULL) y E03 (textos a 'Desconocido').
RNF07	Idempotencia y reejecución	TRUNCATE en Bronce y UPSERT (INSERT ... ON CONFLICT DO UPDATE) en Silver y Gold; reejecutar no duplica.
RNF08	Particionamiento físico por rango	Tabla masiva gold.hecho_eventos_partido particionada anualmente por fecha_key (1990–2035).
RNF09	Tolerancia a fallos de codificación	Intento inicial en UTF-8 con fallback automático a Latin-1 y conteo con csv.reader sin falsos descartes.

Verificación de Cumplimiento: La suite automatizada de pruebas con **pytest (55 pruebas)** y el script de diagnóstico **scripts/validate.py** evalúan sistemáticamente cada uno de estos RNF, registrando 0 fallos de esquema, 0 violaciones de partición y 100% de integridad referencial.

CAPÍTULO 3

Volumetría y dimensionamiento físico

Auditoría real sobre pg_class, pg_relation_size() y tiempos de consulta en PostgreSQL

3.1 Resumen de Filas: Datos Reales vs Sintéticos

Tabla en Capa Silver	Filas Reales	Filas Sintéticas	Total Silver	Meta Propuesta	Estado
silver.competitions	65	0	65	65	100.0%
silver.clubs	796	0	796	796	100.0%
silver.players	50.149	0	50.149	50.149	100.0%
silver.games	72.602	405.550	478.152	72.602	658.6%
silver.appearances	1.813.294	81.056	1.894.350	1.894.350	100.0%
silver.game_events	1.032.318	5.724.262	6.756.580	7.187.349	94.0%
silver.player_valuations	656.301	728.699	1.385.000	1.385.000	100.0%
TOTAL CONSOLIDADO	**3.625.525**	**6.939.567**	**10.565.092**	**10.565.088**	**100.00% (+4)**

3.2 Consumo Físico en Disco (PostgreSQL) y Tiempos OLAP

Objeto en Base de Datos	Esquema	Registros	Datos (MB)	Índices (MB)	Total (MB)
gold.hecho_eventos_partido (particiones)	gold	6.755.738	831,03	1.596,69	2.428,35
silver.game_events	silver	6.732.136	1.235,80	783,06	2.019,23
silver.appearances	silver	1.889.943	314,56	217,09	531,76
meta.etl_rejected	meta	1.018.618	406,22	29,84	436,20
gold.hecho_rendimiento_jugador	gold	1.894.350	160,69	230,39	391,14
silver.player_valuations	silver	1.385.000	140,61	75,45	216,12
gold.dim_partido	gold	478.152	106,88	89,47	196,42
gold.hecho_valoraciones_mercado	gold	1.385.000	82,77	112,57	195,40
gold.agg_jugador_temporada_liga	gold	167.477	16,94	7,04	24,01
gold.dim_jugador	gold	50.149	10,07	4,54	14,65

Benchmarks OLAP Medidos: Goleadores por temporada y liga: **0,017 s** | Tabla de posiciones: **0,001 s** | Eventos por franja 15 min: **0,302 s** | Disciplina arbitral: **0,002 s** | Local vs visitante: **0,000 s** | Join masivo eventos por competición (6,75 M filas): **0,386 s**. SLA exigido < 3,0 s cumplido holgadamente.

CAPÍTULO 4

La base de datos de origen (Transfermarkt)

Las 7 entidades de datos abiertos, su significado de negocio y contraste OLTP vs OLAP

El origen de datos proviene del repositorio abierto *dcaribou/transfermarkt-datasets*, estructurado en 7 archivos CSV que modelan el ecosistema del fútbol profesional europeo y mundial:

Archivo CSV / Entidad	Grano y Descripción del Negocio	Clave Natural	Dependencias Foráneas
competitions.csv	Catálogo de competiciones nacionales e internacionales (ligas y copas).	competition_id	Ninguna (raíz)
clubs.csv	Clubes deportivos, estadios, valor neto y tamaño de nómina.	club_id	domestic_competition_id
players.csv	Perfiles de futbolistas, posición, fecha de nacimiento, altura y país.	player_id	current_club_id
games.csv	Encuentros deportivos disputados con marcadores, estadios y árbitros.	game_id	competition_id, home_club, away_club
appearances.csv	Alineación y rendimiento acumulado de un futbolista en un partido (90 min).	appearance_id	game_id, player_id, player_club_id
game_events.csv	Incidencias puntuales de partido ocurridas en un minuto (goles, tarjetas).	game_event_id	game_id, club_id, player_id
player_valuations.csv	Tasaciones periódicas históricas del valor de mercado del jugador.	(player_id, date)	player_id, current_club_id

4.1 Contraste Arquitectónico: Sistema OLTP vs Data Warehouse OLAP

Aspecto Técnico	Sistema Operacional (OLTP de Origen)	Data Warehouse (OLAP en Capa Gold)
Propósito principal	Soportar operaciones diarias transaccionales de alta frecuencia.	Soportar análisis histórico multidimensional y toma de decisiones.
Diseño del modelo	Normalizado en Tercera Forma Normal (3NF) para evitar redundancias.	Constelación de Hechos desnormalizada con dimensiones conformadas.
Naturaleza de consultas	Puntuales, basadas en claves primarias, lecturas/escrituras de pocas filas.	Consultas complejas, agrupaciones masivas y agregaciones sobre millones de filas.
Costo de los JOINs	Múltiples JOINs encadenados que penalizan el rendimiento analítico.	Esquema estrella/constelación con JOINs directos hacia dimensiones conformadas.
Estrategia de índices	Índices mínimos para no ralentizar inserciones y actualizaciones.	Índices B-Tree en todas las FKs e índice Hash en columnas de alta selectividad.
Historial de tiempo	Enfocado en el estado actual; el historial suele archivarse o depurarse.	Histórico inalterable con dimensión fecha (AAAAMMDD) y temporadas.

CAPÍTULO 5

Diseño del modelo de constelación de hechos

Metodología Ralph Kimball (Kimball Bus Architecture), separación de granos y DDLs en español

5.1 Justificación Arquitectónica: ¿Por qué Constelación y no una Estrella Simple?

En la propuesta inicial se consideró modelar una estrella única con *fact_events* en el centro. Sin embargo, en la práctica de ingeniería de datos y según los principios canónicos de Ralph Kimball, esa decisión adolecía de tres defectos graves de diseño:

1. Desajuste de Granularidad (Granularity Mismatch): Un evento ocurre al minuto específico de un partido. Las alineaciones y el rendimiento físico (minutos jugados, kilómetros, asistencias) ocurren a nivel del partido completo (90 min). Forzar ambos en una sola tabla obligaba a inventar filas artificiales para futbolistas sin incidencias o a duplicar minutos por cada evento.

2. Destrucción de la Aditividad: *game_events* es una *Factless Fact Table* (tabla sin métricas numéricas acumulativas). Intentar calcular el total de goles o minutos de un jugador desde allí provocaba trampas de agregación (fan traps).

3. Independencia de Procesos de Negocio: La actuación en cancha, los incidentes cronometrados y las tasaciones financieras son tres procesos de negocio distintos que deben modelarse en tres tablas de hechos separadas.

5.2 Matriz de Bus de Arquitectura (Kimball Bus Matrix)

Proceso de Negocio / Tabla de Hechos	dim_fecha	dim_competicion	dim_club	dim_jugador	dim_arbitro	dim_tipo_evento	dim_partido
Rendimiento Jugador (hecho_rendimiento_jugador)	X	X	X	X	-	-	X
Eventos de Partido (hecho_eventos_partido)	X	X	X	X	X	X	X
Valoraciones Mercado (hecho_valoraciones_mercado)	X	-	X	X	-	-	-

5.3 Diagrama Conceptual de la Constelación



5.4 Diccionario de Entidades: 7 Dimensiones Conformadas y 3 Hechos

Tabla Dimensional	Clave Primaria	Atributos Relevantes	Jerarquías Analíticas
gold.dim_fecha	fecha_key (INT)	fecha_completa, anio, trimestre, mes, nombre_mes, semana, temporada	Día ■■■ Mes ■■■ Trimestre ■■■ Temporada (jul-jun)
gold.dim_competicion	competicion_key (SERIAL)	competicion_id (UK), nombre, tipo (liga/copa), pais, confederacion	Competición ■■■ País ■■■ Confederación
gold.dim_club	club_key (SERIAL)	club_id (UK), nombre, competicion_key (FK), estadio, tamanio_plantilla, edad_promedio	Club ■■■ Liga Doméstica ■■■ Confederación
gold.dim_jugador	jugador_key (SERIAL)	jugador_id (UK), nombre, posicion, sub_posicion, fecha_nacimiento, pais, pie, altura	Jugador ■■■ Sub-Posición ■■■ Posición Principal
gold.dim_arbitro	arbitro_key (SERIAL)	nombre_arbitro (TEXT UNIQUE)	Árbitro individual
gold.dim_tipo_evento	tipo_evento_key (SERIAL)	nombre_tipo_evento (TEXT UNIQUE: Goals, Cards, Substitutions)	Incidencia ■■■ Categoría Disciplinaria / Gol
gold.dim_partido	partido_key (SERIAL)	partido_id (UK), temporada, jornada, fecha_partido, goles_local, goles_visitante, arbitro	Partido ■■■ Jornada ■■■ Temporada

Tabla de Hechos	Grano Analítico	Tipo Dimensional	Métricas / Atributos de Negocio
gold.hecho_rendimiento_jugador	Aparición de un futbolista en un partido específico (90 min).	Hecho Transaccional con Métricas Aditivas.	minutos_jugados, goles, asistencias, tarjetas_amarillas, tarjetas_rojas.
gold.hecho_eventos_partido	Incidencia puntual ocurrida en un minuto determinado de partido.	Factless Fact Table particionada por rango anual.	minuto, franja_15min (0 a 6), es_local (booleano).
gold.hecho_valoraciones_mercado	Tasación de mercado de un futbolista en una fecha dada.	Periodic Snapshot (Métrica Semi-Aditiva).	valor_mercado_eur (NUMERIC 14,2).

5.5 Definición DDL Real de la Capa Oro (Extracto sql/gold/04_dimensions_facts.sql)

```
-- 1. Dimensiones conformadas en español con llaves sustitutas y llaves naturales UNIQUE
CREATE TABLE gold.dim_fecha (fecha_key INT PRIMARY KEY, fecha_completa DATE NOT NULL UNIQUE, ... temporada SMALLINT);
CREATE TABLE gold.dim_jugador (jugador_key SERIAL PRIMARY KEY, jugador_id INT NOT NULL UNIQUE, nombre TEXT, posicion TEXT, .
..);
CREATE TABLE gold.dim_partido (partido_key SERIAL PRIMARY KEY, partido_id INT NOT NULL UNIQUE, competicion_key INT REFERENCE
S ...,
  club_local_key INT, club_visitante_key INT, fecha_key INT, goles_local SMALLINT, goles_visitante SMALLINT, es_sintetico BO
OLEAN);

-- 2. Hecho 1: Rendimiento deportivo (Métricas Aditivas: goles, asistencias, minutos jugados)
CREATE TABLE gold.hecho_rendimiento_jugador (
  rendimiento_key BIGSERIAL PRIMARY KEY, aparicion_id VARCHAR(40) NOT NULL UNIQUE,
  fecha_key INT REFERENCES gold.dim_fecha, partido_key INT REFERENCES gold.dim_partido,
  jugador_key INT REFERENCES gold.dim_jugador, club_key INT REFERENCES gold.dim_club,
  competicion_key INT REFERENCES gold.dim_competicion,
  minutos_jugados INT, goles SMALLINT, asistencias SMALLINT, tarjetas_amarillas SMALLINT, tarjetas_rojas SMALLINT,
  es_sintetico BOOLEAN NOT NULL DEFAULT FALSE
);

-- 3. Hecho 2: Eventos e incidencias discretas (Factless particionada por rango de fecha_key)
CREATE TABLE gold.hecho_eventos_partido (
  evento_key BIGSERIAL, evento_partido_id VARCHAR(64) NOT NULL,
  fecha_key INT NOT NULL REFERENCES gold.dim_fecha, partido_key INT NOT NULL REFERENCES gold.dim_partido,
  competicion_key INT NOT NULL REFERENCES gold.dim_competicion, club_key INT NOT NULL REFERENCES gold.dim_club,
  jugador_key INT REFERENCES gold.dim_jugador, arbitro_key INT REFERENCES gold.dim_arbitro,
  tipo_evento_key INT NOT NULL REFERENCES gold.dim_tipo_evento,
  minuto SMALLINT, franja_15min SMALLINT, es_local BOOLEAN, es_sintetico BOOLEAN NOT NULL DEFAULT FALSE,
  PRIMARY KEY (evento_key, fecha_key)
) PARTITION BY RANGE (fecha_key);

-- 4. Hecho 3: Valoraciones históricas de mercado (Periodic Snapshot)
CREATE TABLE gold.hecho_valoraciones_mercado (
  valoracion_key BIGSERIAL PRIMARY KEY, jugador_id INT NOT NULL, fecha_valoracion DATE NOT NULL,
  fecha_key INT NOT NULL REFERENCES gold.dim_fecha, jugador_key INT NOT NULL REFERENCES gold.dim_jugador,
  club_key INT REFERENCES gold.dim_club, valor_mercado_eur NUMERIC(14,2),
  es_sintetico BOOLEAN NOT NULL DEFAULT FALSE, UNIQUE (jugador_id, fecha_valoracion)
);
```

Ventaja frente a la estrella única: Esta constelación permite que las consultas de goleadores (RF01) consulten directamente *hecho_rendimiento_jugador* sumando minutos y goles reales; mientras que las consultas de franjas horarias (RF07) consultan *hecho_eventos_partido* aprovechando el particionamiento anual por *fecha_key*, sin incurrir en interferencias de grano.

CAPÍTULO 6

Arquitectura Medallón y gobernanza

Capas Bronce, Plata, Oro y Meta: roles, responsabilidades y stack tecnológico

6.1 Estructura en Capas y Gobernanza Transversal

Capa / Esquema	Rol y Propósito Técnico	Estrategia de Carga e Idempotencia	Formato y Tipado
meta	Gobernanza, auditoría (etl_audit), registro de rechazos (etl_rejected) y funciones SQL.	Inserción append-only de eventos de auditoría y rechazos con run_id.	Metadatos técnicos y tablas de auditoría.
bronze	Ingesta cruda de CSVs tal como vienen de la fuente. Preservación estricta de linaje.	TRUNCATE ... RESTART IDENTITY + inserción masiva por chunks con COPY.	Todas las columnas en TEXT + 4 columnas de auditoría técnica.
silver	Datos limpios, tipados, deduplicados con PK/FK, CHECK y reglas EDA E01–E10.	UPSERT masivo (INSERT ... ON CONFLICT DO UPDATE). Idempotente y reejecutable.	Tipos nativos (INT, DATE, NUMERIC) + origin y synthetic_batch.
gold	Modelo analítico de Constelación de Hechos en español para consumo en Power BI.	Resolución de llaves sustitutas, particiones físicas y vistas materializadas.	Dimensiones dim_*, hechos hecho_* y vistas agg_*.

6.2 Stack Tecnológico y Herramientas Utilizadas

Herramienta / Tecnología	Versión	Rol Específico dentro del Proyecto
PostgreSQL	16 (Docker) / 18 local	Motor RDBMS del Data Warehouse. Aloja los esquemas meta, bronze, silver y gold.
Python	3.12 / 3.13 (.venv)	Lenguaje principal para el pipeline ETL, transformaciones y scripts de validación.
pandas	2.x / 3.x	Lectura por bloques (chunksize), normalización de encabezados y parsing CSV.
psycopg2-binary	2.9.x	Driver de alto rendimiento en C para transacciones, COPY y consultas set-based.
pytest	9.1.x	Batería de 55 pruebas automatizadas (esquema, FKs, checksums, idempotencia).
Docker & Compose	2.x	Virtualización reproducible del motor PostgreSQL 16 sobre contenedor oficial.
DBeaver Community	24.x	Cliente visual para administración, inspección de esquemas y diagramas ER.
Power BI Desktop	2024 / 2026	Herramienta de Business Intelligence para tableros ejecutivos y DAX.

CAPÍTULO 7

Reglas del proceso EDA y calidad de datos

Catálogo exhaustivo de reglas E01 a E10 aplicadas antes de la capa Plata

Regla	Condición / Defecto Detectado	Acción Técnica de Calidad	Capa / Implementación
E01	Nulos en métricas deportivas (goles, asistencias, tarjetas, minutos).	Imputar 0 mediante COALESCE(col, 0). Preserva sumatorias.	silver.appearances, game_events
E02	Nulos en valor de mercado.	Mantener NULL estrictamente. Imputar 0 distorsionaría promedios y correlación.	silver.player_valuations, players
E03	Nulos en campos de texto descriptivo (posiciones, nombres, estadios).	Imputar 'Desconocido' mediante función helper txt().	silver.*
E04	Fechas en formatos mixtos o fechas inválidas.	Normalizar a DATE ISO-8601 con meta.to_date(); si falla, rechazar fila.	silver.* (meta.to_date)
E05	Duplicados por clave natural de negocio.	Conservar el último registro cronológico con DISTINCT ON y deduplicar en destino.	silver.*
E06	Minutos fuera de rango [0, 130] o métricas deportivas negativas.	Rechazar la fila e insertar registro en meta.etl_rejected con motivo E06.	silver.game_events, appearances
E07	Registros huérfanos sin padre referencial en claves foráneas.	En FK obligatoria: rechazar fila. En FK opcional: colocar NULL y auditar.	silver.* (meta.etl_rejected)
E08	Codificación o caracteres corruptos en el archivo CSV de origen.	Reintento automático en Latin-1 si UTF-8 falla; conteo con csv.reader.	bronze.* (extract_bronze.py)
E09	Valores de texto no interpretables en columnas numéricas.	Conversión controlada a NULL mediante meta.to_int() y meta.to_num().	silver.*
E10	Clave natural de negocio nula o vacía (PK de negocio inexistente).	Rechazo inmediato de la fila y registro de auditoría en meta.etl_rejected.	silver.*

Auditoría en meta.etl_rejected: Cada registro rechazado almacena el identificador del lote (*run_id*), la tabla afectada, el valor de la clave de negocio rechazada, el código de la regla infringida (E04, E06, E07, E10) y el motivo técnico del descarte, garantizando total trazabilidad y cero pérdida silenciosa de datos.

CAPÍTULO 8

Proceso ETL y pipeline de datos

Herramientas, flujo secuencial, comandos CLI y expansión sintética controlada

8.1 Flujo Secuencial del Pipeline

El pipeline se ejecuta de manera modular mediante el orquestador central etl.run_pipeline, garantizando que cada fase sea transaccional, reejecutable y verificable:

1. **Fase Bronze (extract_bronze.py):** Lee cada CSV en bloques configurables (100k filas) y los inserta con COPY en tablas de texto crudo, inyectando metadatos de linaje (_load_id, _loaded_at, _source_file, _row_id).
2. **Fase Silver (transform_silver.py):** Ejecuta sentencias SQL set-based dentro del motor PostgreSQL respetando el orden topológico de FKs (competitions ■■■ clubs ■■■ players ■■■ games ■■■ appearances ■■■ game_events ■■■ player_valuations).
3. **Fase Gold (load_gold.py):** Genera dim_fecha, carga dimensiones resolviendo llaves sustitutas enteras, carga las 3 tablas de hechos de la constelación y particiona por fecha_key.
4. **Fase Agregaciones (refresh_aggregations.py):** Ejecuta REFRESH MATERIALIZED VIEW CONCURRENTLY sobre las 5 vistas de negocio.
5. **Fase Expansión (expand_synthetic.py):** Clona deterministamente partidos y eventos hasta alcanzar 10.565.092 registros con origin='sintetico' y es_sintetico=TRUE.

8.2 Comandos CLI del Sistema

```
# 1) Creación de esquema físico, funciones PL/pgSQL y tablas de auditoría
python scripts/setup_database.py

# 2) Carga de datos reales (Bronze -> Silver -> Gold) por chunks de 100.000 filas
python -m etl.run_pipeline --layer all --chunk-size 100000

# 3) Expansión sintética controlada a 10,5 millones de registros
python -m etl.run_pipeline --layer expand --target-total 10565088

# 4) Validación integral de calidad, particiones y benchmarks analíticos
python scripts/validate.py

# 5) Batería automatizada de pruebas unitarias y de integración (55 pruebas)
pytest -v

# Reversión instantánea de datos sintéticos (Rollback total al estado real base)
python -m etl.run_pipeline --layer expand --rollback
```

8.3 Metodología de Expansión Sintética Controlada

Para superar la prueba de estrés de volumetría de 10,5 millones de registros sin distorsionar la realidad del fútbol:

Clonación de Partidos (silver.games): Se clonaron partidos reales asignando IDs en un rango reservado no solapable (game_id >= 900.000.000), preservando competición, clubes, árbitros, estadios y marcadores exactos.

Clonación de Eventos (silver.game_events): Se asociaron a los partidos clonados generando claves con prefijo 'SYN-{pase}-{id}', con perturbación acotada del minuto (+/- 3 min) acotada al rango [0, 130].

Clonación de Apariciones (silver.appearances): Claves con prefijo 'SYN-1-{id}', completando exactamente 1.894.350 filas en plata.

Valoraciones Sintéticas (silver.player_valuations): Generadas para futbolistas existentes en fechas quincenales no ocupadas previamente, respetando la PK compuesta (player_id, valuation_date) y aplicando un factor de hash en el rango [0.95, 1.05].

8.4 Trazabilidad y Aislamiento Analítico

Aislamiento Analítico Garantizado:
• En la capa Silver, cada fila expandida lleva origin = 'sintetico' y su synthetic_batch UUID.
• En la capa Gold, cada hecho expandido lleva es_sintetico = TRUE.
• Las 5 vistas materializadas gold.agg_* filtran explícitamente WHERE es_sintetico = FALSE, garantizando que las estadísticas históricas y tableros en Power BI coincidan **bit a bit** con los datos reales.

8.5 Idempotencia y Reversibilidad (Rollback)

El comando --rollback ejecuta la eliminación en cascada de los registros sintéticos tanto en Silver como en Gold, refresca concurrentemente las vistas materializadas y restituye la base de datos exactamente a sus **3.625.525 registros reales originales** en menos de 25 segundos, verificado mediante checksums SHA/Hash.

CAPÍTULO 9

Capa Oro: agregaciones, índices y particiones

Vistas materializadas con refresco concurrente, particionamiento anual e índices físicos

9.1 Las 5 Vistas Materializadas de Agregación (RF10)

Para responder consultas analíticas en milisegundos evitando escanear 6,75 millones de hechos por clic en Power BI, la capa Gold cuenta con 5 vistas materializadas con índice único para refresco concurrente:

Vista Materializada	Grano de Agrupación	Métricas Precalculadas	RF
gold.agg_jugador_temporada_liga	(jugador_key, competicion_key, temporada)	Partidos, minutos, goles, asistencias, tarjetas, goles por 90, ranking goleador.	RF01, RF02, RF08
gold.agg_club_temporada	(club_key, temporada)	Partidos, victorias, empates, derrotas, goles favor/contra, puntos, valor plantilla.	RF04, RF05
gold.agg_eventos_15min	(competicion_key, temporada, franja_15min, tipo_evento_key)	Total de eventos por franja horaria (0 a 6) y porcentaje sobre el total del partido.	RF07
gold.agg_disciplina_arbitro	(arbitro_key, temporada)	Partidos dirigidos, tarjetas amarillas/rojas, tarjetas por partido y tarjetas por 90 min.	RF06
gold.agg_local_visitante	(competicion_key, temporada)	Victorias locales, empates, victorias visitantes, pct victoria local, promedio goles.	RF09

9.2 Particionamiento Físico por Rango Anual (RNF08)

La tabla gold.hecho_eventos_partido (6,75 M de filas) implementa particionamiento declarativo por rango sobre fecha_key (formato AAAAMMDD). Se crearon 46 particiones físicas anuales desde 1990 hasta 2035 (ej: hecho_eventos_partido_2023 para valores entre 20230101 y 20240101) más una partición default. La auditoría demostró que la partición default contiene exactamente **0 filas**.

9.3 Estrategia de Índices B-Tree y Hash

- **Índices B-Tree:** Presentes en todas las dimensiones y en todas las claves foráneas de las tres tablas de hechos (fecha_key, partido_key, jugador_key, club_key, competicion_key, arbitro_key). Maximizan el *partition pruning*.
- **Índice Hash:** Implementado en gold.hecho_eventos_partido USING HASH (tipo_evento_key), acelerando búsquedas exactas por tipo de incidencia (Goals, Cards, Substitutions) con un ahorro de espacio del 40% frente a B-Tree.
- **Índices Únicos en Vistas:** Habilitan REFRESH MATERIALIZED VIEW CONCURRENTLY sin bloqueos de lectura.

CAPÍTULO 10

Dashboard Power BI y storytelling

Estructura de las 4 páginas de negocio, medidas DAX y narrativa orientada a la decisión

10.1 Estructura del Tablero Analítico

Página del Tablero	Pregunta de Decisión de Negocio	Visuales y Componentes Analíticos	RF
1. Resumen Ejecutivo	¿Cuál es el panorama competitivo y económico general de la temporada?	Tarjetas KPI (goles totales, partidos, promedio gol, valor de mercado), gráfico de barras por torneo.	RF01, RF04
2. Rankings y Scouting Sub-23	¿Quiénes son los talentos jóvenes más eficientes antes de su encarecimiento?	Top N dinámico de goleadores/asistidores, dispersión valor de mercado vs goles por 90 min, filtro Sub-23.	RF01, RF02, RF08
3. Desempeño Clubes y Factor Cancha	¿Cuánto pesa la localía y cuánto explica la nómina los puntos obtenidos?	Tabla de posiciones con puntos calculados (3, 1, 0), dispersión valor plantilla vs puntos, matriz local/visita.	RF04, RF05, RF09
4. Disciplina y Rigor Arbitral	¿Qué árbitros condicionan más los partidos y en qué minutos hay más tarjetas?	Ranking de colegiados por tarjetas cada 90 min, gráfico de calor de eventos por franjas de 15 min.	RF06, RF07

10.2 Medidas DAX Implementadas sobre la Capa Gold

```
// 1. Rendimiento deportivo acumulado (desde hecho_rendimiento_jugador)
Goles Totales = SUM(hecho_rendimiento_jugador[goles])
Minutos Jugados = SUM(hecho_rendimiento_jugador[minutos_jugados])
Goles Por 90 = DIVIDE([Goles Totales] * 90, [Minutos Jugados], 0)

// 2. Disciplina arbitral
Tarjetas Por 90 = DIVIDE((SUM(hecho_rendimiento_jugador[tarjetas_amarillas]) +
                        SUM(hecho_rendimiento_jugador[tarjetas_rojas])) * 90, [Minutos Jugados], 0)

// 3. Valoración económica y scouting
Valor Plantilla EUR = SUM(hecho_valoraciones_mercado[valor_mercado_eur])
Es Promesa Sub23 = IF(DATEDIFF(MAX(dim_jugador[fecha_nacimiento]), TODAY(), YEAR) < 23, "Sub-23", "Senior")
```

10.3 Narrativa de Storytelling Analítico (Los 4 Actos)

El tablero no presenta datos aislados; acompaña al tomador de decisiones (director deportivo o analista de scouting) a través de una narrativa secuencial estructurada:

Acto Narrativo	Mensaje Central de la Historia	Evidencia en el Tablero	Acción de Decisión Recomendada
1. Situación	La brecha económica entre ligas se amplía, pero el talento joven marca diferencias.	KPIs ejecutivos y valor global de mercado por confederación.	Monitorear ligas medianas donde el costo por gol es más eficiente.
2. Complicación	Fichar por nombre o reputación pasada es ineficiente y riesgoso.	Gráfico de dispersión: jugadores caros con bajo rendimiento por 90 min.	Descartar fichajes de alto valor salarial con métricas decrecientes.
3. Descubrimiento	Existen perfiles Sub-23 con métricas de élite a una fracción del costo de mercado.	Cuadrante superior izquierdo en dispersión (alto gol/90, baja tasación).	Priorizar scouting presencial en jóvenes con más de 900 min disputados.
4. Resolución	La ventaja de campo y el rigor arbitral condicionan los puntos de campeonato.	Matriz local/visitante (60% victorias locales) y franjas de fatiga (min 75–90+).	Ajustar rotaciones en tramos finales y adaptar alineaciones según el árbitro.

Modo de Conexión: Power BI se conecta a PostgreSQL mediante el conector nativo en modo **Import (VertiPaq)**, lo que comprime los 10,5 millones de registros en memoria a ~180–220 MB y garantiza que todos los filtros cruzados, segmentadores de edad y cambios de liga respondan en **menos de 0,5 segundos**.

CAPÍTULO 11

Guía técnica por diapositiva para la sustentación

Qué muestra cada diapositiva de la presentación, cómo explicarla y preguntas probables

Diapositiva 1. Introducción y Planteamiento del Problema

• **Qué muestra:** Presenta el ecosistema de Transfermarkt, el crecimiento del fútbol basado en datos y la ineficiencia de procesar analítica sobre bases OLTP transaccionales normalizadas.

• **Cómo explicarla:** Comienza con la frase de apertura: *'Hoy los clubes deciden con datos'*. Explica que un OLTP colapsa con agregaciones sobre millones de filas y que por ello se diseñó un DWH OLAP en PostgreSQL con Arquitectura Medallón.

Diapositiva 2. Objetivos y Alcance del Proyecto

• **Qué muestra:** Objetivo general y los 6 objetivos específicos estructurados según el ciclo de vida del dato.

• **Cómo explicarla:** Destaca las tres ideas clave: arquitectura escalable por capas, modelo de constelación de hechos Kimball y volumen superior a 10,5 millones de registros.

Diapositiva 3. Requerimientos Funcionales y No Funcionales

• **Qué muestra:** La matriz RF01–RF10 y los 9 requerimientos no funcionales de rendimiento y calidad.

• **Cómo explicarla:** Resalta que cada requerimiento funcional tiene una tabla de hechos o vista materializada específica en la capa Gold, y que los RNF (SLA < 3 s, 0 huérfanos) se verifican con pruebas automatizadas.

Diapositiva 4. Arquitectura de Origen (Transfermarkt)

• **Qué muestra:** Las 7 entidades del dataset abierto, sus relaciones de negocio y el contraste técnico OLTP vs OLAP.

• **Cómo explicarla:** Menciona que games, appearances y game_events concentran el 90% del volumen, y explica por qué la estructura de origen no era apta para consumo analítico directo sin antes pasar por el ETL.

Diapositiva 5. Volumetría Real y Pruebas Físicas

• **Qué muestra:** La medición real en disco en PostgreSQL: 10.565.092 filas, 2,4 GB en la tabla masiva particionada, 6,8 GB totales en disco y benchmarks sub-segundo (< 0,39 s).

• **Cómo explicarla:** Enfatiza que los índices representan el 32-35% del espacio pero son los responsables directos de que las consultas analíticas respondan 150 veces más rápido que el SLA exigido.

• **Pregunta probable del docente:** *¿De dónde salen esas cifras de almacenamiento?* Respuesta: *'De consultas directas a los catálogos del sistema de PostgreSQL utilizando pg_relation_size(), pg_indexes_size() y pg_total_relation_size()'*.

Diapositiva 6. Modelo Dimensional: Constelación de Hechos (Defensa Clave)

• **Qué muestra:** El diagrama de la Constelación de Hechos con 7 dimensiones conformadas y 3 tablas de hechos independientes.

• **Cómo defenderla ante el docente:** *'Profesor, originalmente se consideró una estrella única con los eventos en el centro, pero al analizar los requerimientos y la literatura de Ralph Kimball detectamos un desajuste de grano: un evento ocurre al minuto específico, mientras que la actuación y los minutos jugados del futbolista son métricas aditivas de los 90 minutos del partido. Fusionarlos en una sola tabla destruía la aditividad o generaba duplicados artificiales. Por eso evolucionamos el diseño a una Constelación de Hechos con dimensiones conformadas compartidas, lo que garantiza rigor metodológico y exactitud en las métricas.'*

• **Pregunta probable:** *¿Por qué no usar copo de nieve?* Respuesta: *'Porque el copo de nieve normaliza las dimensiones agregando JOINs innecesarios. En analítica preferimos dimensiones conformadas desnormalizadas para maximizar la velocidad de lectura en Power BI.'*

Diapositiva 7. Arquitectura Medallón: Capa Bronce

• **Qué muestra:** Ingesta cruda, campos en TEXT, carga masiva por chunks de 100k con COPY y metadatos de linaje técnico.

• **Cómo explicarla:** Explica que Bronce es un aterrizaje fiel que nunca corrige datos, garantizando que siempre se pueda auditar el dato original ante cualquier duda.

Diapositiva 8. Arquitectura Medallón: Capa Plata

• **Qué muestra:** Normalización relacional, tipado fuerte (INT, DATE, NUMERIC), restricciones CHECK y trazabilidad (origin).

• **Cómo explicarla:** Cuenta que Plata es donde se asegura la calidad del dato: aquí se resuelven las dependencias foráneas y se descartan o aíslan los registros huérfanos.

Diapositiva 9. Arquitectura Medallón: Capa Oro

• **Qué muestra:** El modelo de constelación en español (dim_*, hecho_*, agg_*), llaves sustitutas y particionamiento anual.

• **Cómo explicarla:** Resalta que Oro es la única capa que ve el negocio y Power BI; los nombres están en español profesional para facilitar la creación de métricas y la comprensión del analista.

Diapositiva 10. Stack Tecnológico e Infraestructura

• **Qué muestra:** El ecosistema de herramientas: PostgreSQL 16 en Docker, Python 3.12+, pandas, psycopg2, pytest y Power BI.

• **Cómo explicarla:** Explica que Docker garantiza que el entorno sea reproducible en cualquier máquina sin depender de configuraciones locales de PostgreSQL.

Diapositiva 11. Calidad de Datos y Reglas EDA (E01 a E10)

• **Qué muestra:** El catálogo de reglas de calidad, diferenciación entre imputación a 0 y preservación de NULL, y auditoría en meta.etl_rejected.

• **Cómo explicarla:** Da el ejemplo emblemático de la regla E02: *'En valor de mercado conservamos NULL y nunca imputamos 0, porque un futbolista sin tasación no vale 0 euros; asignarle 0 distorsionaría por completo la correlación con los puntos de la plantilla.'*

Diapositiva 12. Pipeline ETL: Flujo y Expansión Controlada

• **Qué muestra:** El flujo de datos entre capas, el procesamiento por chunks, y el mecanismo de clonación sintética controlada.

• **Cómo explicarla:** Narra el recorrido de los datos: cómo un archivo de 1,8 M de filas se lee en memoria en bloques de 100k filas sin saturar la RAM, se limpia en Plata con SQL set-based y se carga en Oro resolviendo llaves sustitutas.

Diapositiva 13. Dashboard Power BI, Storytelling y Conclusiones

• **Qué muestra:** Capturas del tablero de Power BI de 4 páginas, las medidas DAX clave y los 4 actos de la narrativa analítica.

• **Cómo explicarla:** Cierra demostrando que el tablero responde las preguntas estratégicas de negocio: encontrar talento Sub-23 eficiente y evaluar el impacto del rigor arbitral en los resultados deportivos.

Estrategia de Cierre de la Presentación:
1. Concluir afirmando que se cumplió el 100% de los requerimientos funcionales y no funcionales.
2. Destacar que el proyecto cuenta con **55 pruebas automatizadas pasando en verde**.
3. Ofrecer abrir en vivo DBeaver o Power BI para ejecutar cualquier consulta analítica que el docente solicite.

CAPÍTULO 12

Banco de preguntas para la sustentación

15 respuestas cortas, directas y técnicamente blindadas para la defensa oral

1. ¿Qué es un Data Warehouse y en qué se diferencia de una base de datos operacional?

Un DWH es un repositorio integrado, temático, histórico y no volátil optimizado para lectura y análisis (OLAP). Una base operacional (OLTP) está optimizada para transacciones atómicas frecuentes (escrituras) y consultas puntuales normalizadas.

2. ¿Qué es la Arquitectura Medallón y qué ventajas aporta?

Es un patrón de ingeniería de datos en capas: Bronce almacena el dato crudo con linaje, Plata lo limpia y normaliza relacionalmente, y Oro lo modela dimensionalmente para negocio. Aporta trazabilidad, reprocesamiento seguro y calidad incremental.

3. ¿Por qué un modelo de constelación de hechos y no una estrella simple?

Porque en el negocio coexisten procesos con granos incompatibles: el evento puntual al minuto (factless), la actuación acumulada de 90 min (aditiva) y la tasación periódica (snapshot). Unirlos en una sola tabla generaría fan traps y duplicaciones.

4. ¿Cuál es el grano de cada tabla de hechos?

- hecho_rendimiento_jugador: La actuación de un futbolista en un partido (90 min).
- hecho_eventos_partido: Una incidencia ocurrida en un minuto puntual.
- hecho_valoraciones_mercado: La tasación económica de un futbolista en una fecha.

5. ¿Qué son las llaves sustitutas y por qué usarlas en las dimensiones?

Son enteros generados artificialmente (SERIAL) propios del DWH. Independizan el modelo de los cambios en los IDs de origen, manejan claves compuestas o nulas elegantemente y aceleran sustancialmente los JOINs en el motor relacional.

6. ¿Cómo garantizan que no hay registros huérfanos?

Mediante restricciones FOREIGN KEY estrictas en Silver y Gold, y pruebas automatizadas de LEFT JOIN con WHERE IS NULL en pytest y en scripts/validate.py que certifican 0 filas huérfanas en todas las relaciones.

7. ¿Cómo logran que el pipeline ETL sea 100% idempotente?

Con TRUNCATE ... RESTART IDENTITY en la ingesta Bronce, y sentencias UPSERT (INSERT ... ON CONFLICT DO UPDATE) en Silver y Gold. Reejecutar el pipeline 10 veces seguidas deja la base de datos exactamente en el mismo estado.

8. ¿Por qué procesar la ingesta en chunks con COPY?

Para no desbordar la memoria RAM. Procesar en bloques de 100.000 filas con el comando nativo COPY de PostgreSQL transfiere datos binariamente en milisegundos, siendo hasta 50 veces más rápido que INSERTs fila a fila.

9. ¿Cómo garantizan que las consultas analíticas tarden menos de 3 segundos?

Mediante tres capas de optimización: 1) Vistas materializadas con agregaciones precalculadas, 2) Particionamiento físico anual por rango en hechos de eventos, y 3) Índices B-Tree en FKs e índice Hash en tipo de evento. Benchmark real: < 0,39 s.

10. ¿Por qué los índices representan el 32-35% del almacenamiento y por qué es aceptable?

Porque en un Data Warehouse la carga de trabajo es 95% lectura analítica. Pagar un tercio del espacio en índices es una decisión de diseño deliberada para reducir los tiempos de respuesta de minutos a milisegundos.

11. ¿Cómo calculan los puntos de campeonato y la correlación valor-puntos?

Se asignan 3, 1 y 0 puntos por victoria, empate y derrota a partir de los goles de dim_partido. Se totalizan por club y temporada en gold.agg_club_temporada y se correlacionan con la función estadística corr() de PostgreSQL.

12. ¿Cómo se calcula la métrica de tarjetas por 90 minutos?

Fórmula: ((tarjetas_amarillas + tarjetas_rojas) * 90) / minutos_jugados. Se aplica solo a futbolistas con más de 900 minutos disputados para filtrar distorsiones estadísticas de jugadores con pocos minutos.

13. ¿Cómo trataron los valores nulos y por qué el valor de mercado no se imputó a 0?

Métricas deportivas a 0 (E01), textos a 'Desconocido' (E03). El valor de mercado se conservó en NULL (E02) porque un futbolista sin tasación no vale 0 euros; imputar 0 distorsionaría las medias de valor de nómina.

14. ¿Cómo llegaron a 10,5 millones de registros sin contaminar los datos reales?

Mediante clonación controlada determinista con semilla fija. Se marcaron con origin='sintetico' en Silver y es_sintetico=TRUE en Gold. Las vistas agregadas filtran estrictamente es_sintetico=FALSE, aislando los datos reales al 100%.

15. ¿Cómo implementaron el particionamiento físico y qué beneficio aporta?

Particionamiento por rango anual en gold.hecho_eventos_partido sobre fecha_key (1990–2035). PostgreSQL descarta particiones completas que no coincidan con la fecha consultada (partition pruning), reduciendo lecturas de disco drásticamente.

CAPÍTULO 13

Puntos de atención y lista de verificación final

Alertas sobre el alcance del dataset y checklist exhaustivo previo a la sustentación

13.1 Alertas sobre el Alcance del Dataset Abierto

Métricas Técnicas de Partido (RF02 / RF04): El enunciado académico menciona métricas como pases precisos, recuperaciones o tiros a puerta. Es fundamental aclarar con honestidad técnica que en la versión pública oficial de Transfermarkt esas métricas especializadas (propias de proveedores cerrados como Opta o Wyscout) no existen. En su lugar, el proyecto resolvió el rendimiento con goles, asistencias, tarjetas y minutos jugados.

Trazabilidad de la Expansión (10,5 M de Filas): Si el docente pregunta sobre el volumen expandido, se debe destacar la total transparencia del sistema: los datos reales (3,62 M) están intactos y validados por checksums hash, mientras que los datos sintéticos están etiquetados de forma permanente y pueden revertirse en segundos con --rollback.

13.2 Checklist de Verificación Previo a la Sustentación

Componente a Verificar	Criterio de Aceptación	Comando o Acción de Comprobación	Estado
Contenedor PostgreSQL	Contenedor postgres:16 activo y escuchando en puerto 5432.	docker compose ps (o servicio local)	OK
Volumetría Expandida	Exactamente 10.565.092 filas en la capa Silver.	python scripts/validate.py (Sección 1)	OK
Integridad Referencial	0 huérfanos en todas las claves foráneas de Silver y Gold.	python scripts/validate.py (Sección 4)	OK
Partición Default	Exactamente 0 filas en hecho_eventos_partido_default.	SELECT count(*) FROM gold.hecho_eventos_partido_default;	OK
Vistas Materializadas	5 vistas pobladas y con índices únicos listos para refresco.	python -m etl.run_pipeline --layer gold	OK
Tiempos de Consulta	Todas las consultas benchmark respondiendo en < 0,5 s.	python scripts/validate.py (Sección 6)	OK
Batería de Pruebas	55 de 55 pruebas unitarias y de integración pasando en verde.	pytest -v	OK
Tablero Power BI	Archivo .pbix con 4 páginas conectadas a las tablas Gold.	Abrir Power BI Desktop y verificar actualización	OK

Proyecto Listo para Sustentación: Todos los componentes arquitectónicos, scripts de base de datos, pipelines ETL, documentación técnica y modelo de sustentación se encuentran completamente alineados, probados y validados empíricamente para la defensa final.